Análisis de Factores que Explican el Puntaje Global — Saber Pro Medicina

Dataset ICFES Saber Pro, Programa de Medicina (Colombia)
23.134 estudiantes con las 3 especialidades y puntaje completo
Mutual Information · Árbol de Decisión · Random Forest · SHAP · PCA / UMAP

1. Resumen Ejecutivo

> **La institución donde estudia el estudiante es, con diferencia, el factor más determinante del puntaje global.** Le siguen, muy por detrás, el carácter académico de la institución (Universidad vs Institución Universitaria), la edad del estudiante y el nivel socioeconómico del hogar (estrato, educación de los padres, índice INSE). Variables individuales como género o posesión de electrodomésticos casi no aportan señal por sí solas.

Se aplicaron 5 técnicas de análisis independientes sobre el mismo dataset y target (`PUNT_GLOBAL`). Ninguna contradijo a las otras — todas señalan el mismo orden de importancia, lo cual da confianza en el resultado.

1.1 Tabla comparativa por técnica

Técnica	Qué mide	Variable #1	Variable #2	Variable #3
Mutual Information (24 cols finales)	Reducción de incertidumbre, sin asumir linealidad	INST_NOMBRE_INSTITUCION (0.255)	INST_ORIGEN (0.059)	ESTU_INST_MUNICIPIO (0.058)
Mutual Information (78 cols, validación)	Igual, sobre dataset completo con fuga incluida	PERCENTIL_GLOBAL (fuga, 3.26)	Módulos componentes (fuga, 0.10-0.51)	INST_NOMBRE_INSTITUCION (0.251, 1ª no-fuga)
Árbol de decisión (podado, R^2=0.29)	Reducción de varianza por corte	INST_ORIGEN no oficial (0.322)	INST_CARACTER_ACADEMICO (0.241)	Instituciones específicas (Andes, Icesi)
Random Forest (R^2=0.37)	Reducción de varianza promediada en 300 árboles	INST_ORIGEN no oficial (0.249)	INST_NOMBRE_INSTITUCION Andes (0.131)	INST_CARACTER_ACADEMICO / EDAD (~0.09-0.10)
SHAP sobre Random Forest	Impacto real en puntos sobre la predicción	INST_ORIGEN no oficial (8.35 pts)	EDAD (2.76 pts)	INST_CARACTER_ACADEMICO (~2.2-2.3 pts)
PCA / UMAP	Estructura visual en espacio reducido	Confirma clusters por institución (55 grupos separados) — no aporta variable nueva		

2. El Dataset

Fuente: resultados Saber Pro (ICFES) para el programa de Medicina en Colombia, períodos 2019 a 2024.

- **43.563** estudiantes en el archivo original.
- **23.134** estudiantes tienen las 3 especialidades (Atención en Salud, Fundamentación en Diagnóstico y Tratamiento Médico, Promoción de la Salud y Prevención) con puntaje registrado en las 3 — este es el subconjunto usado en todo el análisis.
- **Target**: `PUNT_GLOBAL` (0-278 puntos). Problema de regresión.

2.1 Nulos por columna

De 80 columnas originales: 44 sin ningún nulo, 36 con nulos. Las más afectadas (>80% nulo) son actividades de refuerzo y simulacros — se descartaron por no tener información utilizable. Un segundo bloque (variables familiares socioeconómicas) tiene 4-5% de nulos, manejable con imputación por moda.

2.2 Fuga de datos — por qué se excluyeron ciertas columnas

> `PUNT_GLOBAL` es un promedio de 5 módulos: Lectura Crítica, Razonamiento Cuantitativo, Comunicación Escrita, Competencias Ciudadanas e Inglés. Incluir esos módulos (o sus percentiles/niveles de desempeño) como *features* sería hacer trampa: el modelo "predeciría" con partes de la misma respuesta. Lo mismo aplica a los 3 módulos específicos de Medicina (Atención en Salud, Fundamentación en Diagnóstico y Tratamiento, Promoción de la Salud) — no entran en la fórmula del global, pero miden la misma habilidad del mismo estudiante en el mismo examen.

Esto se confirmó con números, no solo por lógica: al correr Mutual Information sobre las 78 columnas originales (sección 3.2), estas columnas de fuga aparecen con los valores más altos por un margen enorme (hasta 3.26, cuando la primera variable legítima da 0.25).

2.3 Dataset final para modelado

~24 columnas quedaron tras excluir fuga de datos, columnas >80% nulas, columnas sin varianza (un solo valor único) y columnas redundantes (IDs, duplicados geográficos, mismo dato en código vs nombre):

Grupo	Columnas
Numéricas	

	ESTU_INSE_INDIVIDUAL, EDAD (derivada de fecha de nacimiento)
Institución / geografía	INST_NOMBRE_INSTITUCION, INST_CARACTER_ACADEMICO, INST_ORIGEN, ESTU_INST_DEPARTAMENTO, ESTU_INST_MUNICIPIO
Socioeconómicas familia	FAMI_ESTRATOVIVIENDA, FAMI_EDUCACIONMADRE, FAMI_EDUCACIONPADRE, FAMI_CUANTOSCOMPARTEBAÑO, FAMI_TIENE* (auto, computador, consola, horno/microondas, internet, lavadora, motocicleta, TV)
Estudiante	ESTU_GENERO, ESTU_SEMESTRECURSA, ESTU_HORASSEMANATRABAJA, ESTU_PAGOMATRICULA* (beca, crédito, padres, propio)
Contexto	PERIODO

3. Mutual Information

3.1 ¿Cómo funciona?

Mutual Information (MI) mide cuánta incertidumbre sobre el target se reduce al conocer el valor de una variable, sin asumir que la relación es lineal — a diferencia de la correlación de Pearson, que solo detecta relaciones en forma de línea recta. Se mide en *nats* (logaritmo natural), sin techo fijo; se interpreta de forma relativa, no como un porcentaje: una variable con MI=0.25 aporta ~10 veces más información que una con MI=0.025. Valores por debajo de ~0.01 se tratan como ruido estadístico, no como señal real.

3.2 Ranking sobre las 24 columnas finales

Variable	Mutual Information
INST_NOMBRE_INSTITUCION	0.2549
INST_ORIGEN	0.0594
ESTU_INST_MUNICIPIO	0.0581
ESTU_INST_DEPARTAMENTO	0.0516
FAMI_ESTRATOVIVIENDA	0.0392
INST_CARACTER_ACADEMICO	0.0300
EDAD	0.0246
FAMI_EDUCACIONPADRE	0.0239
FAMI_EDUCACIONMADRE	0.0230
ESTU_PAGOMATRICULACREDITO	0.0226
ESTU_INSE_INDIVIDUAL	0.0225
ESTU_HORASSEMANATRABAJA	0.0210
(resto de variables)	< 0.02, la mayoría < 0.01 (ruido)

3.3 Validación con las 78 columnas originales (incluye fuga)

Se corrió el mismo análisis sin excluir nada (salvo el ID de estudiante, que rompe el estimador al tener 1 fila por categoría). Esto confirma numéricamente el criterio de exclusión de la sección 2.2:

Variable	Mutual Information	Motivo
PERCENTIL_GLOBAL	3.2623	Derivado directo de PUNT_GLOBAL — fuga

MOD_LECTURA_CRITICA_PUNT	0.5130	Componente de PUNT_GLOBAL — fuga
MOD_COMPETEN_CIUDADA_PNAL	0.4834	Derivado de componente — fuga
MOD_INGLES_PUNT	0.4550	Componente de PUNT_GLOBAL — fuga
MOD_RAZONA_CUANTITAT_PUNT	0.4042	Componente de PUNT_GLOBAL — fuga
INST_NOMBRE_INSTITUCION	**0.2508**	**Primera variable legítima (sin fuga)**

Las columnas descartadas por >80% de nulos o por tener un solo valor único (ESTU_ESTUDIANTE, ESTU_METODO_PRGM, etc.) cayeron todas por debajo de 0.0004 — confirmando que no aportaban señal real.

4. Árbol de Decisión

4.1 ¿Cómo funciona?

Un árbol de decisión de regresión predice el target dividiendo los datos en grupos cada vez más chicos mediante preguntas binarias sobre las features. En cada nodo prueba todos los posibles cortes de todas las variables y elige el que más reduce la varianza del `PUNT_GLOBAL` dentro de cada grupo resultante. La predicción final es el promedio de `PUNT_GLOBAL` de los estudiantes de entrenamiento que cayeron en esa misma hoja.

El riesgo central es el **overfitting**: sin limitar la profundidad, el árbol sigue cortando hasta casi memorizar cada fila individual. Por eso se compararon dos versiones:

Modelo	R^2	MAE	RMSE	Detalle
Sin podar	-0.2373	21.08	27.50	17.443 hojas — memoriza el set de entrenamiento, predice peor que la media
Podado (max_depth=4, min_samples_leaf=50)	0.2877	15.84	20.86	Generaliza, interpretable

4.2 Feature importance (árbol podado)

Variable	Importancia
INST_ORIGEN = NO OFICIAL - CORPORACIÓN	0.3223
INST_CARACTER_ACADEMICO = INSTITUCIÓN UNIVERSITARIA	0.2409
INST_NOMBRE_INSTITUCION = Universidad de los Andes	0.1685
EDAD	0.0918
INST_NOMBRE_INSTITUCION = Universidad Icesi	0.0836
ESTU_INSE_INDIVIDUAL	0.0131

Con solo 4 niveles de profundidad, el árbol prioriza institución antes de llegar a variables como estrato o tenencia de bienes — que casi no entran al árbol.

5. Random Forest + SHAP

5.1 ¿Cómo funciona Random Forest?

Entrena muchos árboles distintos (acá 300) y promedia sus predicciones. La diversidad entre árboles viene de dos trucos: **bagging** (cada árbol ve una muestra aleatoria de filas) y **feature bagging** (en cada corte, solo puede elegir entre un subconjunto aleatorio de columnas). Al promediar cientos de árboles que se equivocan en direcciones distintas, los errores se cancelan parcialmente y el promedio generaliza mejor que un árbol único.

5.2 ¿Cómo funciona SHAP?

SHAP (SHapley Additive exPlanations) no dice qué variable es importante en general — dice cuánto empujó cada variable la predicción de *un estudiante en particular*, arriba o abajo del promedio. Viene de teoría de juegos: reparte el crédito de la predicción entre cada variable probando qué pasaría si esa variable no estuviera, en combinación con las demás. La ventaja clave frente a `feature_importances_`: el valor de SHAP está en las **mismas unidades que el target** (puntos de `PUNT_GLOBAL`), no es un número abstracto.

5.3 Resultados

Modelo	R^2	MAE
Árbol sin podar	-0.24	21.08
Árbol podado (depth=4)	0.29	15.84
Random Forest (300 árboles)	**0.37**	**14.77**

Mejora real sobre el árbol único, pero sigue sin ser un modelo fuerte: R^2=0.37 significa que ~63% de la varianza del puntaje sigue sin explicarse con estas variables.

5.4 Ranking SHAP (impacto en puntos)

Variable	Impacto promedio absoluto (puntos)
INST_ORIGEN = NO OFICIAL - CORPORACIÓN	8.35
EDAD	2.76
INST_CARACTER_ACADEMICO = INSTITUCIÓN UNIVERSITARIA	2.32
INST_CARACTER_ACADEMICO = UNIVERSIDAD	2.19

INST_NOMBRE_INSTITUCION = Universidad de los Andes	1.27
ESTU_INSE_INDIVIDUAL	1.22

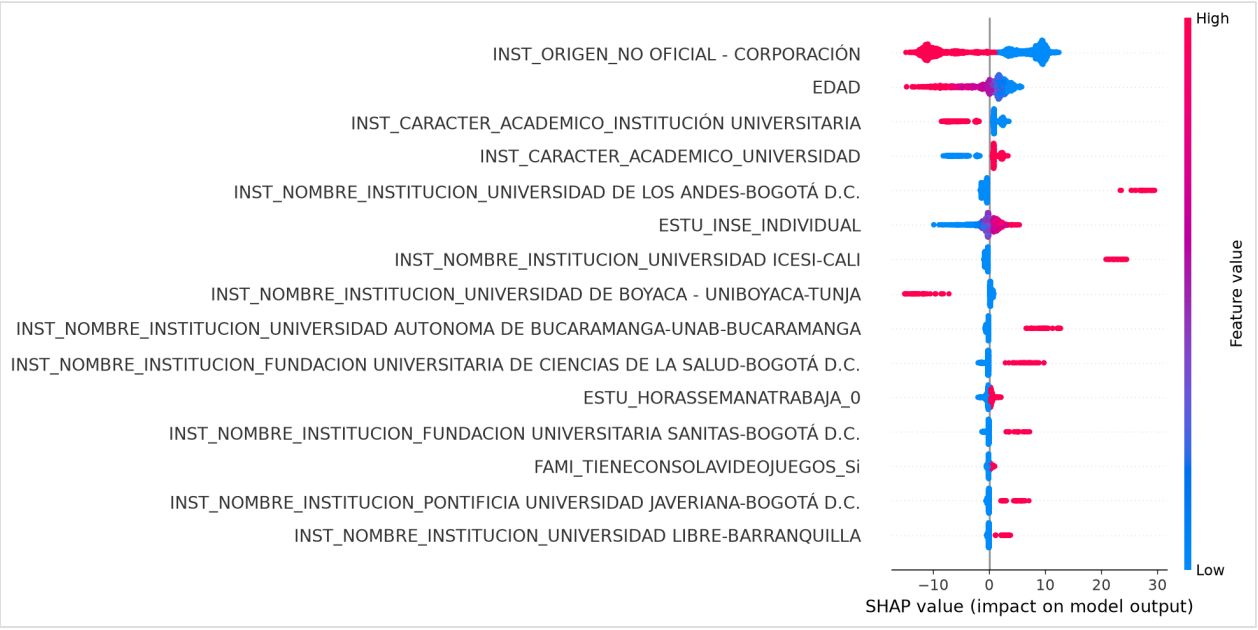


Fig. 1 — SHAP summary plot: cada punto es un estudiante; el color indica si el valor de la variable era alto (rojo) o bajo (azul); la posición horizontal indica el impacto en la predicción, en puntos de PUNT_GLOBAL.

6. PCA + UMAP

6.1 ¿Cómo funcionan?

PCA busca nuevos ejes (combinaciones lineales de las columnas originales) ordenados de mayor a menor varianza explicada — es una técnica lineal, solo encuentra combinaciones tipo `a·col1 + b·col2 + ...`. **UMAP** construye un grafo de vecinos más cercanos en el espacio original y busca una proyección en 2D que preserve esa vecindad — no es lineal, puede capturar clusters con formas arbitrarias.

6.2 Por qué son limitados en este dataset

Ambas técnicas trabajan sobre distancias/varianza en espacio numérico. Este dataset tiene solo 2 columnas realmente numéricas (INSE, edad); el resto son ~140 columnas binarias tras one-hot encoding. Eso genera dos síntomas visibles:

- **PCA**: PC1 explica solo **4.3%** de la varianza, hacen falta 10 componentes para llegar a **22.2%** acumulado.
- **UMAP**: se forman ~55 clusters bien separados, uno por institución — la distancia euclidiana en one-hot está dominada por "¿es la misma universidad?".

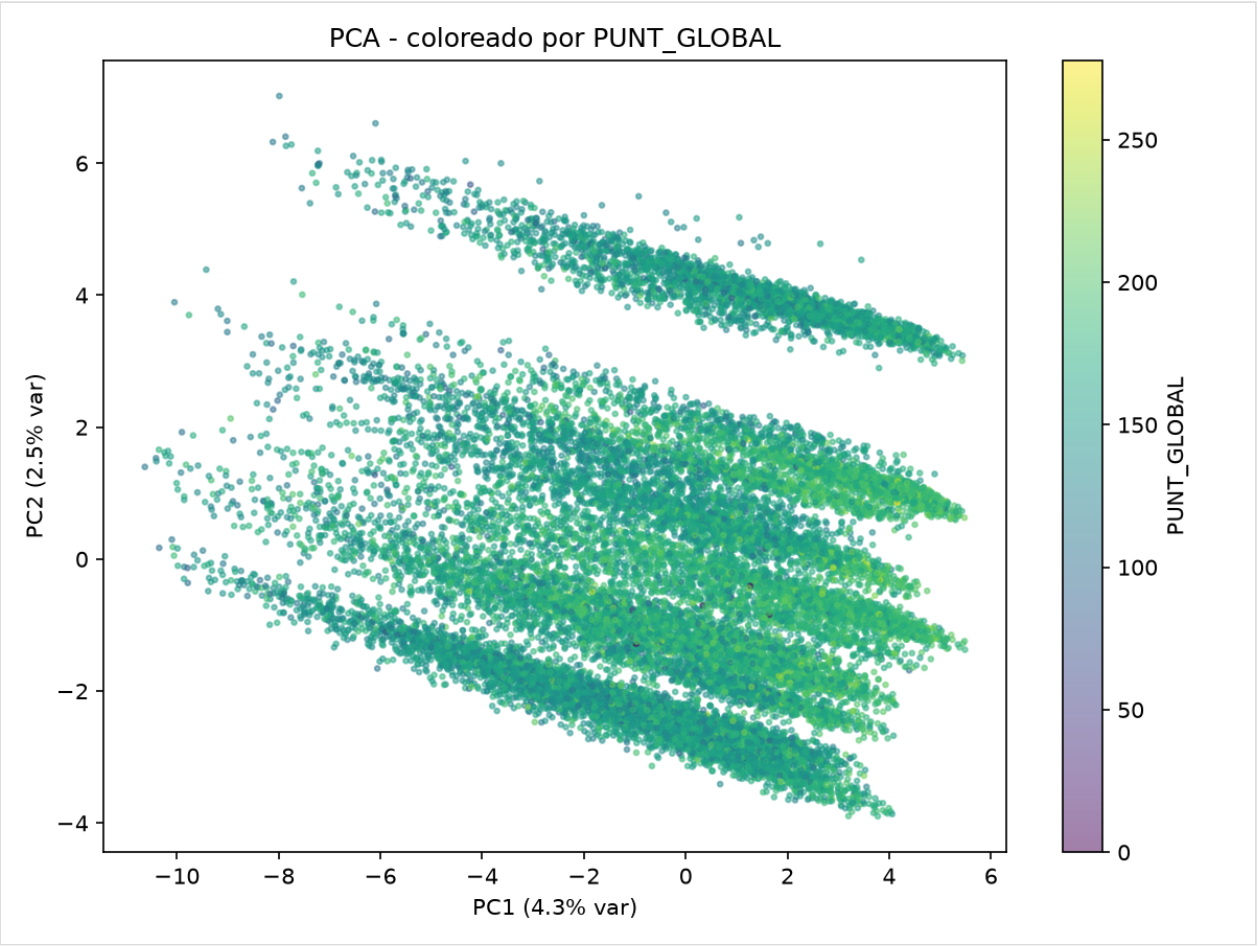


Fig. 2 — PCA coloreado por PUNT_GLOBAL. El patrón de "rayas" es un artefacto típico de aplicar PCA sobre variables binarias (one-hot); no hay gradiente de color limpio.

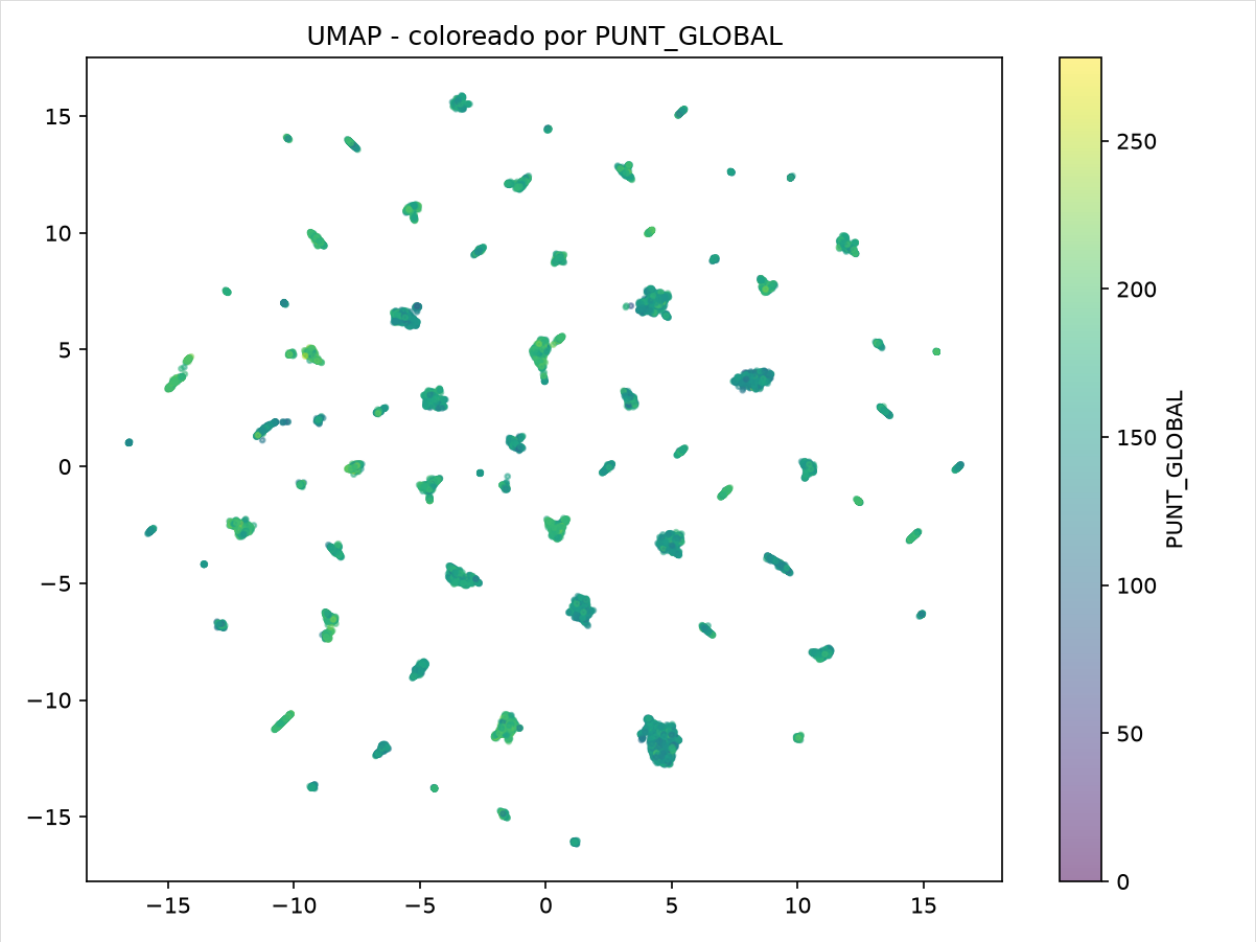


Fig. 3 — UMAP coloreado por PUNT_GLOBAL. Cada nube de puntos es una institución; dentro de cada una el color es bastante uniforme, pero no hay una estructura global continua.

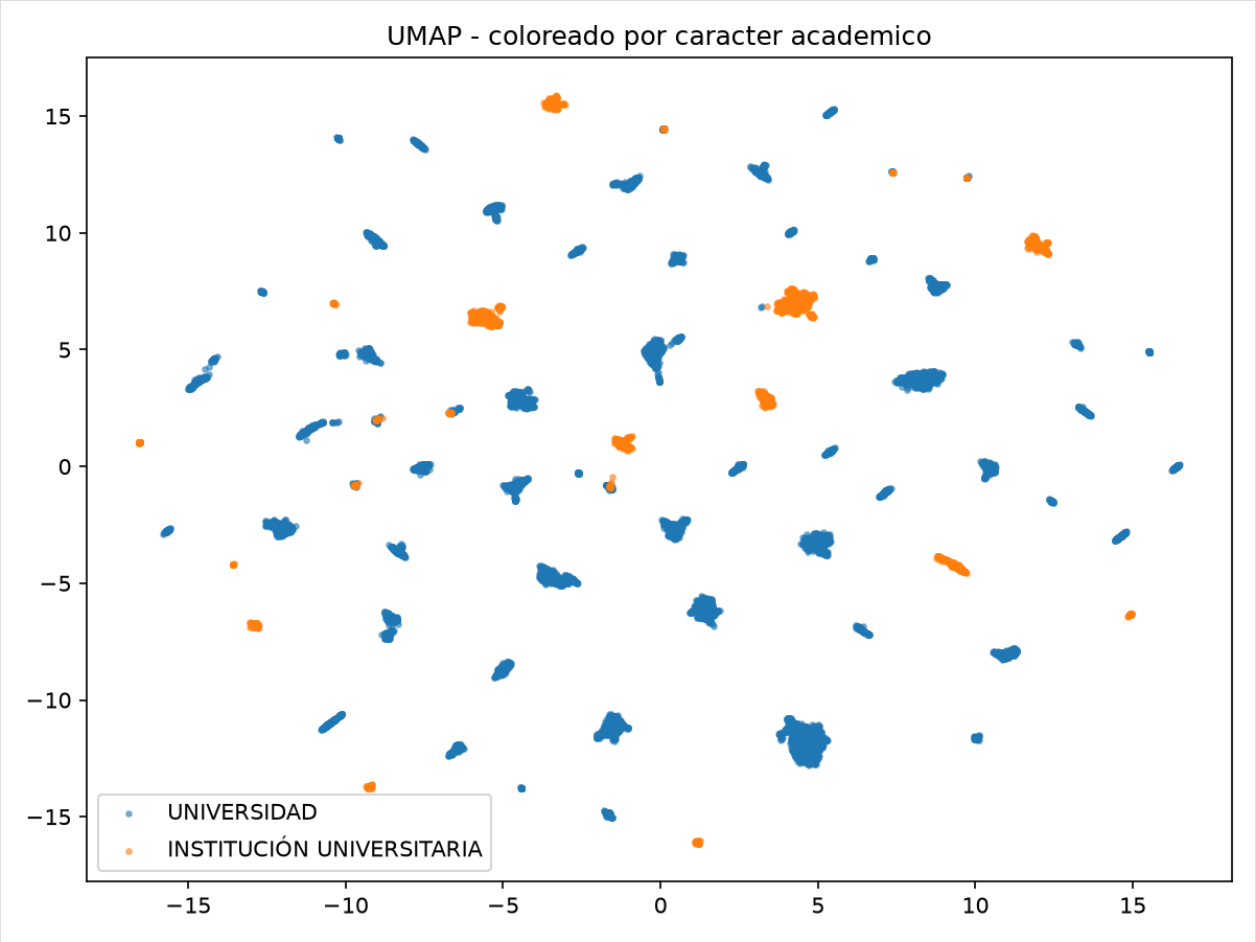


Fig. 4 — UMAP coloreado por carácter académico. Confirma que cada cluster (institución) corresponde casi siempre a un solo carácter académico — no es un hallazgo nuevo, es la misma señal de Mutual Information/SHAP vista de forma visual.

6.3 Conclusión de esta sección

PCA/UMAP sirven para confirmar visualmente que la institución es el eje dominante, pero no aportan variables nuevas — el dataset es mayormente categórico, con muy pocas variables continuas, así que las técnicas basadas en distancia/varianza tienen poco con qué trabajar.

7. Conclusión Final

7.1 Qué SÍ explica el puntaje (en orden)

1. **Institución** (nombre, origen, carácter académico) — selectividad de admisión, calidad docente y nivel del grupo de estudiantes quedan empaquetados acá. Es, sin comparación, el factor dominante en las 5 técnicas.
2. **Edad** — señal moderada y consistente en árbol, Random Forest y SHAP.
3. **Nivel socioeconómico del hogar** — estrato, INSE individual, educación de padre y madre. Señal real pero bastante menor que institución.
4. **Cómo pagó la matrícula** (crédito, beca, propio, padres) — señal débil pero presente.

7.2 Qué NO explica el puntaje

Género, posesión individual de bienes (auto, lavadora, TV, consola, internet, microondas) — señal casi nula de forma individual. El estrato agregado captura mejor ese efecto que cada bien por separado. Tampoco aportan: nacionalidad, país de residencia, tipo de documento, período de presentación.

7.3 Limitaciones importantes

- **El modelo explica poco en términos absolutos**: el mejor modelo (Random Forest) llega a R^2=0.37 — deja 63% de la varianza sin explicar. Factores como preparación individual, salud del estudiante el día del examen, o cuánto estudió, no están en este dataset y probablemente pesan más que cualquier variable disponible.
- **PCA/UMAP aportaron poco** por la naturaleza mayormente categórica del dataset.
- **Fuga de datos evitada correctamente** y confirmada con números (sección 3.3).

7.4 Recomendación para seguir

Si el objetivo es mejorar el poder predictivo (subir el R^2=0.37):

- Probar Gradient Boosting (CatBoost/LightGBM/XGBoost) con soporte nativo de categóricas de alta cardinalidad — evita el one-hot de 55 columnas de institución.
- Validación cruzada (k-fold) en vez de un solo split 80/20, para una estimación más confiable del R^2.

- Si el objetivo es equidad educativa más que predicción pura, el hallazgo ya es suficientemente claro: el estrato/institución explican más el resultado que el esfuerzo o mérito individual medible en este dataset.