Variables asociadas con *PUNT_GLOBAL*

Informe técnico — Saber Pro Medicina (Colombia)

Mutual Information · Árbol de Decisión · Random Forest · SHAP · PCA/UMAP

23.134 estudiantes · períodos 2019–2024 · versión generada desde artefactos reproducibles

Resumen ejecutivo

El tipo de institución es señal real y generalizable; el nombre puntual de la institución no lo es. Nombre, origen y carácter académico ocupan los primeros lugares en todos los métodos predictivos, pero no pesan igual bajo una medición robusta de generalización: `INST_ORIGEN` e `INST_CARACTER_ACADEMICO` (tipo de institución) se mantienen como las variables más importantes al

> medir permutation importance agrupada, mientras que `INST_NOMBRE_INSTITUCION` cae del puesto #1 (MDI) al #24 de 27, con caída de R^2 prácticamente nula — evidencia de memorización, no de señal transferible (ver sección 6.4). Edad e indicadores socioeconómicos aportan señal secundaria; género y muchos bienes del hogar tienen asociación baja. El mejor modelo, Random Forest, alcanza R^2=0.37 en un único split 80/20 — pero al validar con `GroupKFold` agrupando por institución (instituciones de validación nunca vistas en entrenamiento) ese R^2 cae a 0.12 ± 0.15, evidencia adicional de memorización institucional. Combinando la señal institucional real (tipo de institución) con las variables demográficas y socioeconómicas, y validando de nuevo con `GroupKFold` por institución, el modelo final (sección 6.5, etapa 8) alcanza **R^2≈0.23 (0.229 ± 0.087)**: es el número que el proyecto sostiene con más confianza como desempeño honesto y generalizable.

El hallazgo es predictivo y asociativo: no demuestra que una institución cause un puntaje, y gran parte de la variación de `PUNT_GLOBAL` permanece sin explicar incluso en el mejor modelo. Si se remueve la institución por completo (K-Fold sin institución, sección 6.1) el R^2 es ~0.19: una porción real pero modesta de la varianza depende de variables no institucionales. El tipo de institución (origen, carácter académico) sigue siendo la señal más asociada y generalizable al puntaje; en cambio, buena parte del desempeño original de 0.37 —y de la importancia del nombre puntual de la institución— reflejaba patrones específicos de las instituciones vistas en entrenamiento, no una capacidad de generalización a instituciones nuevas.

Método	Señal principal	Lectura
Mutual Information	Institución (0.2549)	MI univariada; sin techo fijo
Árbol podado	Origen institucional (0.3223)	R^2=0.2877; MAE=15.84
Random Forest	Origen institucional (0.2489)	R^2=0.37; MAE=14.77
SHAP	Origen institucional (8.35 puntos)	Impacto absoluto medio
PCA / UMAP	Clusters institucionales	Ver sección 6.6: eran identidad institucional, no estructura independiente

1. Datos, variables y metodología

La fuente es el archivo ICFES Saber Pro de Medicina, con 43.563 registros originales. Se analizaron 23.134 estudiantes con las tres especialidades y puntaje completo. El objetivo es `PUNT_GLOBAL`, tratado como regresión. La edad se deriva de la fecha de nacimiento; se imputan numéricas con mediana y categóricas con moda.

Grupos de variables

- **Institución/geografía:** nombre, origen, carácter académico, departamento y municipio.
- **Socioeconomía:** estrato, educación de madre/padre, baño e indicadores de bienes.
- **Estudiante:** edad, género, semestre, horas de trabajo y pago de matrícula.
- **Contexto:** período e índice INSE.

MI usa codificación ordinal y `mutual_info_regression`; los árboles usan one-hot. La evaluación de árbol y bosque utiliza `train_test_split(test_size=0.2, random_state=0)`. SHAP se calcula con TreeExplainer sobre una muestra de hasta 2.000 estudiantes del test.

Fuga de información y exclusiones

> **No se usan variables de resultado.** Se excluyen los componentes, percentiles y niveles de desempeño del examen, además de los tres módulos específicos de Medicina. Son resultados del mismo examen o derivados de `PUNT_GLOBAL` y producirían fuga.

La comprobación sobre las 78 columnas originales coloca `PERCENTIL_GLOBAL` en MI=3.2623 y los módulos generales aproximadamente entre 0.23 y 0.51; la primera variable legítima es la institución (MI=0.2508). También se eliminaron IDs, columnas constantes/casi vacías y redundancias.

2. Rankings completos

2.1 Mutual Information — variables finales

MI mide reducción de incertidumbre en nats. No es porcentaje de varianza explicada ni prueba causal. El CSV fuente contiene el ranking completo.

Variable	MI
INST_NOMBRE_INSTITUCION	0.2549
INST_ORIGEN	0.0594
ESTU_INST_MUNICIPIO	0.0581
ESTU_INST_DEPARTAMENTO	0.0516
FAMI_ESTRATOVIVIENDA	0.0392
INST_CARACTER_ACADEMICO	0.0300
EDAD	0.0246
FAMI_EDUCACIONPADRE	0.0239
FAMI_EDUCACIONMADRE	0.0230
ESTU_PAGOMATRICULACREDITO	0.0226
ESTU_INSE_INDIVIDUAL	0.0225
ESTU_HORASSEMANATRABAJA	0.0210
FAMI_CUANTOSCOMPARTEBAÑO	0.0207
FAMI_TIENEHORNOMICROOGAS	0.0190
ESTU_PAGOMATRICULABECA	0.0189
FAMI_TIENEAUTOMOVIL	0.0140
FAMI_TIENECONSOLAVIDEOJUEGOS	0.0124
FAMI_TIENEMOTOCICLETA	0.0115
ESTU_SEMESTRECURSA	0.0112
FAMI_TIENELAVADORA	0.0088
FAMI_TIENECOMPUTADOR	0.0067
PERIODO	0.0056
ESTU_PAGOMATRICULAPROPIO	0.0049
FAMI_TIENEINTERNET	0.0046
ESTU_PAGOMATRICULAPADRES	0.0038
ESTU_GENERO	0.0029
FAMI_TIENESERVICIOTV	0.0027

2.2 Validación de fuga — 20 mayores MI de las 78 columnas

Variable (validación 78 columnas)	MI
PERCENTIL_GLOBAL	3.2623
MOD_LECTURA_CRITICA_PUNT	0.5130
MOD_LECTURA_CRITICA_PNAL	0.5114

Variable (validación 78 columnas)	MI
MOD_LECTURA_CRITICA_PNBC	0.5006
MOD_COMPETEN_CIUDADA_PNAL	0.4834
MOD_COMPETEN_CIUDADA_PUNT	0.4751
MOD_COMPETEN_CIUDADA_PNBC	0.4731
MOD_INGLES_PUNT	0.4550
MOD_INGLES_PNAL	0.4534
MOD_INGLES_PNBC	0.4508
MOD_RAZONA_CUANTITAT_PUNT	0.4042
MOD_RAZONA_CUANTITATIVO_PNAL	0.3947
MOD_RAZONA_CUANTITATIVO_PNBC	0.3863
MOD_LECTURA_CRITICA_DESEM	0.3839
MOD_COMPETEN_CIUDADA_DESEM	0.3745
MOD_INGLES_DESEM	0.3421
Puntaje_Atencion_en_Salud	0.3295
Puntaje_Promocion_Salud_Prevencion	0.2583
INST_NOMBRE_INSTITUCION	0.2508
ESTU_SNIES_PRGMACADEMICO	0.2478

3. Árbol de decisión

El modelo interpretado es un árbol podado (`max_depth=4`, `min_samples_leaf=50`): R^2=0.2877, MAE=15.84 y RMSE=20.86. El árbol sin podar alcanza R^2=-0.2373 por sobreajuste y tiene 17.443 hojas.

La importancia suma la reducción de varianza de los cortes one-hot; no equivale a un efecto individual.

Variable/categoría	Importancia
INST_ORIGEN_NO OFICIAL - CORPORACIÓN	0.3223
INST_CARACTER_ACADEMICO_INSTITUCIÓN UNIVERSITARIA	0.2409
INST_NOMBRE_INSTITUCION_UNIVERSIDAD DE LOS ANDES-BOGOTÁ D.C.	0.1685
EDAD	0.0918
INST_NOMBRE_INSTITUCION_UNIVERSIDAD ICESI-CALI	0.0836
INST_NOMBRE_INSTITUCION_UNIVERSIDAD DE BOYACA - UNIBOYACA-TUNJA	0.0366
INST_NOMBRE_INSTITUCION_FUNDACION UNIVERSITARIA DE CIENCIAS DE LA SALUD-BOGOTÁ D.C.	0.0261
INST_NOMBRE_INSTITUCION_FUNDACION UNIVERSITARIA SANITAS-BOGOTÁ D.C.	0.0150
ESTU_INSE_INDIVIDUAL	0.0131
PERIODO_20243	0.0014
ESTU_GENERO_M	0.0005
FAMI_CUANTOSCOMPARTEBAÑO_NINGUNA	0.0004

4. Random Forest y SHAP

El bosque promedia 300 árboles (`max_depth=8`, `min_samples_leaf=20`), reduciendo la varianza del árbol individual. Resultados del split: R^2=0.37, MAE=14.77. El ranking completo de importancia clásica es:

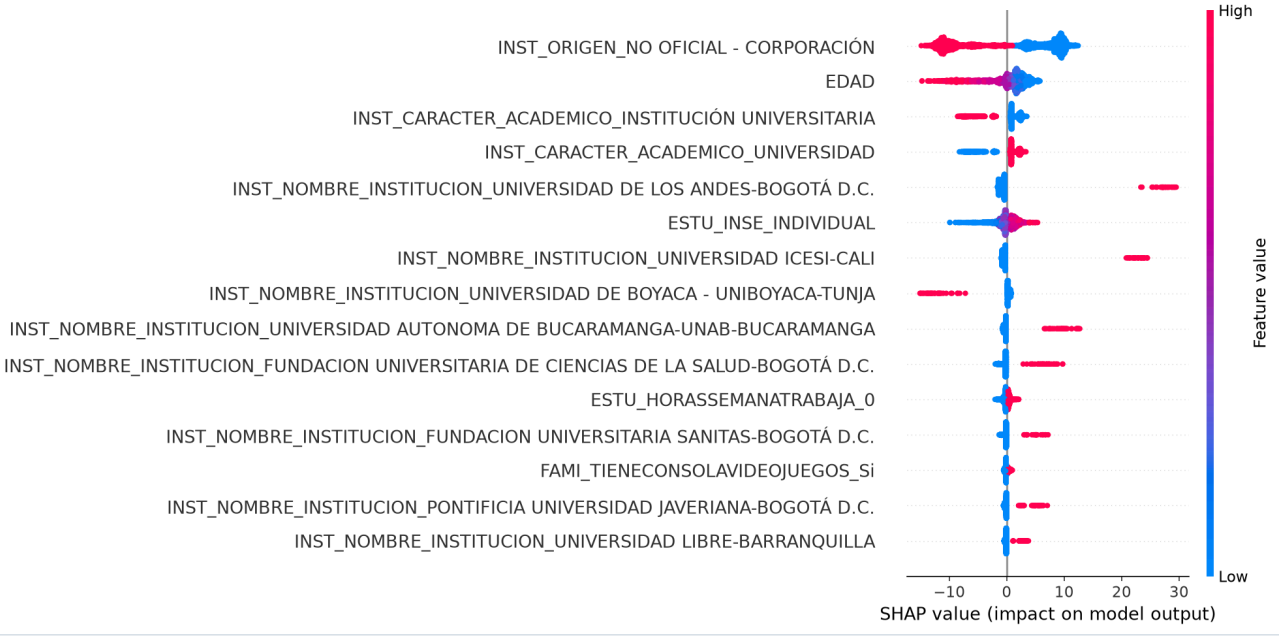
Variable/categoría	Importancia
INST_ORIGEN_NO OFICIAL - CORPORACIÓN	0.2489
INST_NOMBRE_INSTITUCION_UNIVERSIDAD DE LOS ANDES-BOGOTÁ D.C.	0.1310
INST_CARACTER_ACADEMICO_INSTITUCIÓN UNIVERSITARIA	0.0963
EDAD	0.0960
INST_CARACTER_ACADEMICO_UNIVERSIDAD	0.0912
INST_NOMBRE_INSTITUCION_UNIVERSIDAD ICESI-CALI	0.0647
ESTU_INSE_INDIVIDUAL	0.0511
INST_NOMBRE_INSTITUCION_UNIVERSIDAD DE BOYACA - UNIBOYACA-TUNJA	0.0298
INST_NOMBRE_INSTITUCION_UNIVERSIDAD AUTONOMA DE BUCARAMANGA-UNAB-BUCARAMANGA	0.0201
INST_NOMBRE_INSTITUCION_FUNDACION UNIVERSITARIA DE CIENCIAS DE LA SALUD-BOGOTÁ D.C.	0.0199
INST_NOMBRE_INSTITUCION_FUNDACION UNIVERSITARIA SANITAS-BOGOTÁ D.C.	0.0112
INST_NOMBRE_INSTITUCION_PONTIFICIA UNIVERSIDAD JAVERIANA-BOGOTÁ D.C.	0.0083
ESTU_HORASSEMANATRABAJA_0	0.0069
INST_NOMBRE_INSTITUCION_UNIVERSIDAD METROPOLITANA-BARRANQUILLA	0.0061
INST_NOMBRE_INSTITUCION_UNIVERSIDAD LIBRE-CALI	0.0058
INST_NOMBRE_INSTITUCION_UNIVERSIDAD LIBRE-BARRANQUILLA	0.0056
ESTU_INST_MUNICIPIO_CARTAGENA DE INDIAS	0.0049
INST_NOMBRE_INSTITUCION_FUNDACION UNIVERSITARIA SAN MARTIN-BOGOTÁ D.C.	0.0044
FAMI_TIENECONSOLAVIDEOJUEGOS_Si	0.0043
INST_NOMBRE_INSTITUCION_UNIVERSIDAD NACIONAL DE COLOMBIA-BOGOTÁ D.C.	0.0042

SHAP: impacto en puntos

SHAP explica la predicción del bosque en unidades de `PUNT_GLOBAL`. Los valores son magnitudes absolutas promedio: no indican dirección por sí solos. Por ejemplo, 8.35 puntos para origen institucional no significa que cada caso cambie exactamente esa cantidad.

Variable/categoría	Impacto medio absoluto (puntos)
INST_ORIGEN_NO OFICIAL - CORPORACIÓN	8.35
EDAD	2.76
INST_CARACTER_ACADEMICO_INSTITUCIÓN UNIVERSITARIA	2.32
INST_CARACTER_ACADEMICO_UNIVERSIDAD	2.19
INST_NOMBRE_INSTITUCION_UNIVERSIDAD DE LOS ANDES-BOGOTÁ D.C.	1.27
ESTU_INSE_INDIVIDUAL	1.22
INST_NOMBRE_INSTITUCION_UNIVERSIDAD ICESI-CALI	0.80
INST_NOMBRE_INSTITUCION_UNIVERSIDAD DE BOYACA - UNIBOYACA-TUNJA	0.57

Variable/categoría	Impacto medio absoluto (puntos)
INST_NOMBRE_INSTITUCION_UNIVERSIDAD AUTONOMA DE BUCARAMANGA-UNAB-BUCARAMANGA	0.48
INST_NOMBRE_INSTITUCION_FUNDACION UNIVERSITARIA DE CIENCIAS DE LA SALUD-BOGOTÁ D.C.	0.44
ESTU_HORASSEMANATRABAJA_0	0.41
INST_NOMBRE_INSTITUCION_FUNDACION UNIVERSITARIA SANITAS-BOGOTÁ D.C.	0.28
FAMI_TIENECONSOLAVIDEOJUEGOS_Si	0.26
INST_NOMBRE_INSTITUCION_PONTIFICIA UNIVERSIDAD JAVERIANA-BOGOTÁ D.C.	0.24
INST_NOMBRE_INSTITUCION_UNIVERSIDAD LIBRE-BARRANQUILLA	0.23
FAMI_TIENECONSOLAVIDEOJUEGOS_No	0.22
INST_NOMBRE_INSTITUCION_UNIVERSIDAD METROPOLITANA-BARRANQUILLA	0.21
INST_NOMBRE_INSTITUCION_FUNDACION UNIVERSITARIA SAN MARTIN-BOGOTÁ D.C.	0.19
ESTU_INST_MUNICIPIO_CARTAGENA DE INDIAS	0.19
INST_NOMBRE_INSTITUCION_UNIVERSIDAD LIBRE-CALI	0.17



SHAP summary plot: distribución de impactos por estudiante.

5. Síntesis y lectura sustantiva

Patrón común

Los cuatro métodos cuantitativos coinciden en la centralidad de la institución. Sin embargo, esa aparente equivalencia entre nombre, origen y carácter académico no sobrevive a una medición más robusta de generalización — ver sección 6.4 (etapa 7): el nombre puntual resulta ser memorización, mientras que origen y carácter académico (tipo de institución) son la señal institucional que realmente se transfiere a instituciones nuevas. La edad aparece de manera estable en árbol, bosque y SHAP; estrato, INSE y educación familiar tienen una asociación menor; género, período y la mayoría de bienes del hogar tienen señal baja. PCA/UMAP forman aproximadamente 55 agrupaciones institucionales — pero, como confirma la sección 6.6 (etapa 9), esas agrupaciones dependen enteramente de incluir `INST_NOMBRE_INSTITUCION` como feature: al removerla, los ~55 clusters desaparecen, evidencia de que eran identidad institucional (una isla por universidad) y no una variable explicativa independiente.

Qué no debe concluirse

- No puede afirmarse que cambiar de institución cause un cambio concreto de puntaje.
- Una importancia alta puede reflejar confusión entre selección, ubicación, recursos y composición del alumnado.
- Las importancias no son coeficientes ni significancia estadística.
- No puede sostenerse que el nombre puntual de una institución (`INST_NOMBRE_INSTITUCION`) tenga poder predictivo transferible a instituciones nuevas: bajo permutation importance agrupada (sección 6.4) cae del puesto #1 en MDI al #24 de 27, con caída de R^2 prácticamente nula.

Limitaciones

- Asociación no implica causalidad.
- El nombre de institución es categórico y de alta cardinalidad. *Abordado empíricamente* en la sección 6.1: al remover la institución (etapa 5, CV k=5) el R^2 cae de 0.374 a 0.186±0.011.
- Un solo split limita la incertidumbre de las métricas y rankings. *Abordado empíricamente* en las secciones 6.1 y 6.2: K-Fold (etapa 5) y GroupKFold por institución (etapa 6) muestran que el R^2=0.374 del split único cae a 0.120±0.146 al validar contra instituciones nunca vistas.
- El nombre de institución no es señal transferible. *Abordado empíricamente* en la sección 6.4 (etapa 7): la permutation importance agrupada muestra que el nombre cae del puesto #1 (MDI=0.2952) al #24 de 27 con caída de $R^2 \approx 0$, mientras que origen y carácter académico institucional se mantienen —y suben— como las variables más importantes.
- Faltan preparación, horas de estudio, salud y trayectoria escolar.
- PCA/UMAP dependen de one-hot y de parámetros de visualización. *Abordado empíricamente* en la sección 6.6 (etapa 9): al remover `INST_NOMBRE_INSTITUCION` y las variables de ubicación institucional, los ~55 clusters de la etapa 4 desaparecen y son reemplazados por un blob difuso sin partición nítida, confirmando que representaban identidad institucional y no estructura sustantiva independiente. El punto conceptual de fondo —que siguen siendo herramientas exploratorias— permanece válido.

6. Validación de robustez: institución sin variable propia y generalización a instituciones nuevas

Las dos limitaciones anteriores —codificación institucional y un único split— se atacaron empíricamente reentrenando el mismo Random Forest de referencia (`n_estimators=300, max_depth=8, min_samples_leaf=20`) bajo dos esquemas adicionales.

6.1 Etapa 5 — sin variables de institución, con K-Fold (k=5)

Se removieron `INST_NOMBRE_INSTITUCION` , `INST_CARACTER_ACADEMICO` , `INST_ORIGEN` , `ESTU_INST_DEPARTAMENTO` y `ESTU_INST_MUNICIPIO` , evaluando con K-Fold (k=5, shuffle, `random_state=0`): R^2=0.186±0.011, MAE=17.21±0.18, RMSE=22.30±0.23. Quitar institución reduce el R^2 de ~0.37 a ~0.19: se pierde más de la mitad del poder explicativo del modelo. Las variables más importantes pasan a ser socioeconómicas y demográficas (edad, horas de trabajo, INSE individual, forma de pago de matrícula, estrato, educación de los padres), con importancias estables entre folds (coeficiente de variación ~7-10% en el top de la lista).

Variable	Importancia media (CV k=5, sin institución)
EDAD	0.1497
ESTU_HORASSEMANATRABAJA_0	0.1027
ESTU_INSE_INDIVIDUAL	0.1007
ESTU_PAGOMATRICULACREDITO_No	0.0775
ESTU_PAGOMATRICULACREDITO_Si	0.0734
ESTU_PAGOMATRICULABECA_Si	0.0441
ESTU_PAGOMATRICULABECA_No	0.0417
FAMI_ESTRATOVIVIENDA_Estrato 6	0.0397
FAMI_EDUCACIONPADRE_Postgrado	0.0336
FAMI_TIENEMOTOCICLETA_Si	0.0234
FAMI_TIENEMOTOCICLETA_No	0.0230
FAMI_ESTRATOVIVIENDA_Estrato 1	0.0182
FAMI_ESTRATOVIVIENDA_Estrato 5	0.0173
FAMI_TIENECONSOLAVIDEOJUEGOS_No	0.0150
FAMI_TIENECONSOLAVIDEOJUEGOS_Si	0.0148
FAMI_TIENEHORNOMICROOGAS_Si	0.0148
FAMI_TIENEHORNOMICROOGAS_No	0.0147
ESTU_SEMESTRECURSA_12 o más	0.0130
FAMI_ESTRATOVIVIENDA_Estrato 3	0.0129
FAMI_CUANTOSCOMPARTEBAÑO_3 o 4	0.0118

6.2 Etapa 6 — con institución, GroupKFold por institución (k=5)

Se entrenó el mismo modelo con el set completo de variables (incluida institución), usando `GroupKFold(n_splits=5)` agrupado por `INST_NOMBRE_INSTITUCION`, de modo que las instituciones de validación de cada fold nunca aparecen en su entrenamiento (55 instituciones únicas, ninguna supera ~7% de las filas): R^2=0.120±0.146, MAE=17.59±1.07, RMSE=22.78±1.53. El R^2 por fold (0.159, 0.013, 0.250, 0.252, -0.074) tiene una dispersión muy alta, con un fold negativo. Las variables ligadas a una institución puntual (p. ej. Universidad de los Andes: std/media ≈73%; Universidad Icesi: ≈56%) son muy inestables entre folds, mientras que `EDAD` (≈4%), `ESTU_INSE_INDIVIDUAL` (≈15%) y `INST_CARACTER_ACADEMICO_*` (≈21%) se mantienen más estables.

Variable	Importancia media (GroupKFold k=5, con institución)
INST_ORIGEN_NO OFICIAL - CORPORACIÓN	0.2427
INST_NOMBRE_INSTITUCION_UNIVERSIDAD DE LOS ANDES-BOGOTÁ D.C.	0.1029
INST_CARACTER_ACADEMICO_INSTITUCIÓN UNIVERSITARIA	0.0923
INST_CARACTER_ACADEMICO_UNIVERSIDAD	0.0895
EDAD	0.0882
INST_NOMBRE_INSTITUCION_UNIVERSIDAD ICESI-CALI	0.0640
ESTU_INSE_INDIVIDUAL	0.0435
INST_NOMBRE_INSTITUCION_UNIVERSIDAD DE BOYACA - UNIBOYACA-TUNJA	0.0253
INST_NOMBRE_INSTITUCION_UNIVERSIDAD AUTONOMA DE BUCARAMANGA-UNAB-BUCARAMANGA	0.0198
INST_NOMBRE_INSTITUCION_FUNDACION UNIVERSITARIA DE CIENCIAS DE LA SALUD-BOGOTÁ D.C.	0.0183
ESTU_INST_MUNICIPIO_BOGOTÁ D.C.	0.0145
ESTU_INST_DEPARTAMENTO_BOGOTÁ	0.0143
INST_NOMBRE_INSTITUCION_PONTIFICIA UNIVERSIDAD JAVERIANA-BOGOTÁ D.C.	0.0103
INST_ORIGEN_OFICIAL DEPARTAMENTAL	0.0085
INST_NOMBRE_INSTITUCION_FUNDACION UNIVERSITARIA SANITAS-BOGOTÁ D.C.	0.0083
FAMI_TIENEHORNOMICROOGAS_Si	0.0081
INST_NOMBRE_INSTITUCION_UNIVERSIDAD LIBRE-CALI	0.0080
FAMI_TIENEHORNOMICROOGAS_No	0.0075
INST_NOMBRE_INSTITUCION_UNIVERSIDAD LIBRE-BARRANQUILLA	0.0067
ESTU_HORASSEMANATRABAJA_0	0.0061

6.3 Comparación de R^2 entre esquemas de validación

Etapa	Esquema de validación	¿Incluye institución?	R^2
Etapa 3	Split único 80/20 (instituciones compartidas train/test)	Sí (completa)	0.374
Etapa 5	KFold aleatorio, k=5 (instituciones compartidas dentro de cada fold)	No	0.186 ± 0.011
Etapa 6	GroupKFold, k=5 (instituciones de validación nunca vistas)	Sí (completa)	0.120 ± 0.146
Etapa 8 (recomendado)	GroupKFold, k=5 (instituciones de validación nunca vistas)	Solo INST_ORIGEN + INST_CARACTER_ACADEMICO	0.229 ± 0.087

El R^2 de etapa 6 (0.12±0.15) no solo es muy inferior al de etapa 3 (0.374): también queda por debajo del de etapa 5 (0.186±0.011), que ni siquiera usa variables de institución. Esto es evidencia de que el modelo de etapa 3 memorizaba patrones específicos de las instituciones vistas en entrenamiento, en lugar de aprender una relación

generalizable entre las variables socioeconómicas/académicas y `PUNT_GLOBAL`. Esto matiza —no invalida— el hallazgo central: la institución sigue siendo la señal dominante, pero parte del R^2=0.37 original reflejaba el diseño de validación (split único, sin agrupar por institución) más que capacidad predictiva genuina sobre instituciones nuevas. La sección 6.4 (etapa 7) precisa este punto a nivel de variable individual.

6.4 Etapa 7 — Permutation importance agrupada vs. MDI/Gini: nombre vs. tipo de institución

La importancia MDI/Gini (etapas 3 y 6) sobreestima variables categóricas de alta cardinalidad, porque el algoritmo de construcción de árboles tiene más oportunidades de encontrar un split que reduzca impureza cuantas más categorías tenga la variable, aunque ese split no generalice fuera de muestra. `INST_NOMBRE_INSTITUCION` se expande a 55 columnas dummy, la de mayor cardinalidad del feature set con margen. Para probarlo, se replicó el mismo `GroupKFold(n_splits=5)` de etapa 6 y se calculó, por variable original (agregando sus columnas dummy), tanto la MDI agregada como la **permutation importance agrupada**: en cada fold de validación se permutan a la vez todas las dummies de una variable y se mide la caída de R^2 respecto al modelo sin permutar (`n_repeats=5`). A diferencia de MDI, la permutación se mide en validación, con instituciones nunca vistas en entrenamiento.

Variable	Rank MDI	Rank permutación	MDI media	Permutación media
INST_ORIGEN	2	1	0.2544	0.2634
INST_CARACTER_ACADEMICO	3	2	0.1818	0.1344
EDAD	4	3	0.0882	0.0616
ESTU_INSE_INDIVIDUAL	5	4	0.0435	0.0138
INST_NOMBRE_INSTITUCION	1	24	0.2952	-0.0000
ESTU_INST_DEPARTAMENTO	7	26	0.0286	-0.0317
ESTU_INST_MUNICIPIO	6	27	0.0292	-0.0323

El resultado es contundente: `INST_NOMBRE_INSTITUCION` —la variable "más importante" según MDI (0.2952, puesto #1)— cae al puesto #24 de 27 en permutation importance, con caída de R^2 prácticamente cero (ruido numérico): romper la identidad de la institución en validación no cambia el poder predictivo del modelo, porque la importancia MDI se generaba sobre splits de instituciones de *entrenamiento* que `GroupKFold` nunca comparte con las de validación. `ESTU_INST_MUNICIPIO` y `ESTU_INST_DEPARTAMENTO` (proxies geográficos de institución) colapsan igual, con importancia por permutación **negativa** (ranks #26-27). En cambio, `INST_ORIGEN` e `INST_CARACTER_ACADEMICO` —de baja cardinalidad, compartidas entre instituciones de entrenamiento y validación— **suben** de ranking (#2→#1 y #3→#2) y quedan como las dos variables más importantes bajo este método más robusto; `EDAD` y `ESTU_INSE_INDIVIDUAL` se mantienen estables en el top. La conclusión no es "institución no importa": es que el **tipo/origen de institución es señal real y generalizable**, mientras que la **identidad puntual de la institución es un artefacto de memorización que MDI infla por su alta cardinalidad**.

6.5 Etapa 8 — Modelo final recomendado: señal institucional real + validación honesta

Las etapas 5, 6 y 7 diagnostican el problema por partes; la etapa 8 lo resuelve en un único modelo. Se reentrena el mismo Random Forest de referencia combinando lo que etapa 7 confirmó como señal institucional real y transferible (`INST_ORIGEN`, `INST_CARACTER_ACADEMICO`) con las variables socioeconómicas y demográficas de etapa 5, excluyendo explícitamente las tres variables de memorización (`INST_NOMBRE_INSTITUCION`, `ESTU_INST_DEPARTAMENTO`, `ESTU_INST_MUNICIPIO`). La validación usa el mismo `GroupKFold(n_splits=5)` agrupado por `INST_NOMBRE_INSTITUCION` de etapa 6 —esa columna define

los folds pero nunca entra como feature—, de modo que las instituciones de validación nunca fueron vistas en entrenamiento:

Métrica	Valor
R^2	0.229 ± 0.087
MAE	16.30
RMSE	21.37

Comparación de R^2 entre las cuatro configuraciones evaluadas en el proyecto:

Etapa	Esquema de validación	¿Incluye institución?	R^2
Etapa 3	Split único 80/20 (instituciones compartidas train/test)	Sí (completa)	0.374
Etapa 5	KFold aleatorio, k=5 (instituciones compartidas dentro de cada fold)	No	0.186 ± 0.011
Etapa 6	GroupKFold, k=5 (instituciones de validación nunca vistas)	Sí (completa)	0.120 ± 0.146
Etapa 8 (recomendado)	GroupKFold, k=5 (instituciones de validación nunca vistas)	Solo INST_ORIGEN + INST_CARACTER_ACADEMICO	0.229 ± 0.087

Etapa 8 supera tanto a etapa 5 (+0.043) como a etapa 6 (+0.109) en su propia validación honesta por institución, y lo hace con menos varianza entre folds que etapa 6 (std=0.087 vs. 0.146). Esto confirma, con el mismo esquema de validación riguroso, lo que etapa 7 ya mostraba a nivel de variable individual: `INST_ORIGEN` e `INST_CARACTER_ACADEMICO` aportan poder predictivo real y transferible a instituciones nuevas. Las variables más importantes del modelo final (importancia MDI media entre los 5 folds) son:

Variable	Importancia media (GroupKFold k=5, modelo final)
INST_ORIGEN_NO OFICIAL - CORPORACIÓN	0.2807
EDAD	0.1190
INST_CARACTER_ACADEMICO_INSTITUCIÓN UNIVERSITARIA	0.1175
INST_CARACTER_ACADEMICO_UNIVERSIDAD	0.1110
ESTU_INSE_INDIVIDUAL	0.0855

Las cuatro variables institucionales retenidas concentran juntas más de la mitad de la importancia total, seguidas por `EDAD` y `ESTU_INSE_INDIVIDUAL` como principales predictores no institucionales. Este es el modelo y el feature set que el proyecto recomienda para producción o cualquier uso real: variables socioeconómicas y demográficas del estudiante, variables familiares (`FAMI_*`), variables de matrícula/trabajo, y únicamente `INST_ORIGEN` + `INST_CARACTER_ACADEMICO` como señal institucional — nunca `INST_NOMBRE_INSTITUCION` , `ESTU_INST_DEPARTAMENTO` ni `ESTU_INST_MUNICIPIO` , que no generalizan a instituciones nuevas y solo inflarían artificialmente el desempeño aparente sobre datos históricos.

6.6 Etapa 9 — PCA/UMAP sin institución: ¿los clusters eran reales?

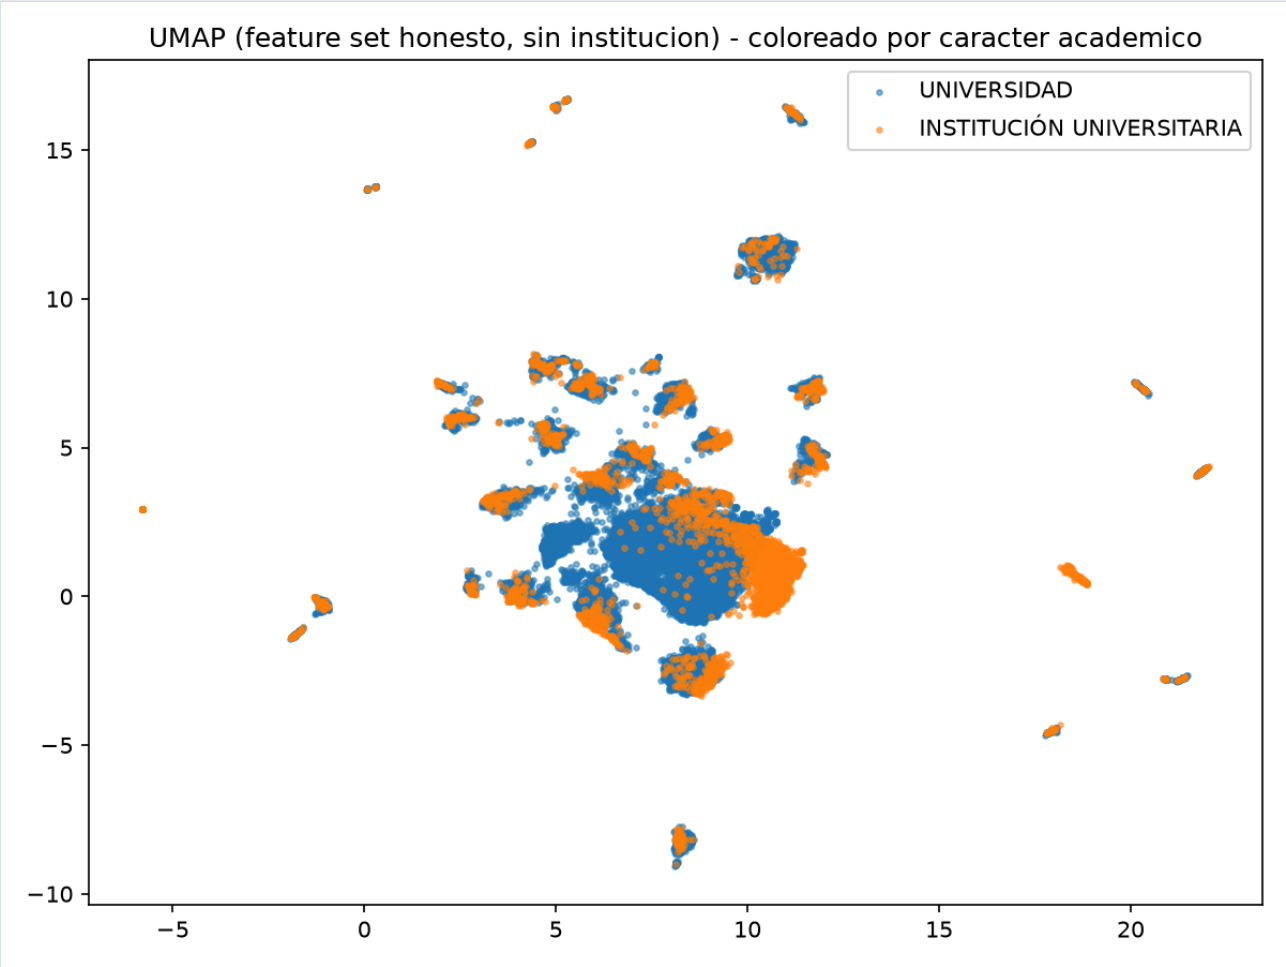
Las etapas 5-8 diagnosticaron y corrigieron la memorización institucional con modelos **supervisados**. La etapa 9 cierra la misma línea de validación con un método **no supervisado**: repite exactamente el pipeline de PCA/UMAP de la etapa 4 (mismo cálculo de `EDAD` , mismo preprocesamiento, mismos hiperparámetros), cambiando únicamente el feature set de entrada al feature set honesto de la etapa 8 (sin `INST_NOMBRE_INSTITUCION` , `ESTU_INST_DEPARTAMENTO` ni `ESTU_INST_MUNICIPIO` ; con `INST_ORIGEN` e `INST_CARACTER_ACADEMICO`).

Etapa	Feature set	Varianza acumulada (10 PCs)
Etapa 4	Completo (incluye INST_NOMBRE_INSTITUCION, 55 categorías)	22.2%

Etapa	Feature set	Varianza acumulada (10 PCs)
Etapa 9	Honesto (sin institución/geografía puntual)	30.7%

La varianza explicada **sube** al quitar la institución, no baja: al remover `INST_NOMBRE_INSTITUCION` (~55 categorías) y las columnas de departamento/municipio del one-hot, se elimina una gran cantidad de columnas dummy dispersas que antes diluían la varianza entre decenas de componentes; con menos dimensiones dispersas, cada componente principal remanente concentra proporcionalmente más señal. En ambos casos la varianza explicada sigue siendo baja en términos absolutos, consistente con un dataset mayormente categórico de baja cardinalidad y sin estructura lineal fuerte.

El patrón de la etapa 4 (~55-60 islas pequeñas, compactas y monocromáticas, coincidente con el número de instituciones) desaparece por completo al remover la institución. En su lugar aparece un blob central grande y denso con sub-estructura interna difusa, rodeado de unos 15-20 grupos periféricos pequeños que ya no se alinean uno a uno con institución ni con carácter académico: en el coloreado por `INST_CARACTER_ACADEMICO`, tanto el blob central como la mayoría de los grupos periféricos aparecen con ambas categorías entremezcladas. Una cuantificación con KMeans + silhouette score (k=2 a 15) no encuentra un pico interior claro, consistente con un continuo de baja cohesión y no con ~55 grupos discretos.



UMAP sin institución, coloreado por carácter académico: sin correspondencia 1:1 cluster-institución (etapa 9).

Los ~55 clusters de la etapa 4 eran, en su gran mayoría, artefactos de identidad institucional puntual (un cluster por universidad), no estructura sustantiva sobre el desempeño académico o el perfil del estudiante. Esto confirma con clustering no supervisado —un método completamente independiente— lo mismo que las etapas 6 y 7 ya habían mostrado con modelos supervisados: la identidad puntual de institución es memorización/sobreajuste, y el feature set honesto de la etapa 8 produce además una representación de PCA/UMAP mucho más consistente con datos socioeconómicos/demográficos reales.

7. Reproducibilidad y referencias

Para regenerar el informe desde la raíz:

`python docs/conclusiones/generar_pdf.py`

Las dependencias de Python están fijadas con versión exacta en `requirements.txt` (raíz del repositorio): `python3 -m venv .venv && source .venv/bin/activate && pip install -r requirements.txt`.

El generador lee automáticamente estos artefactos:

- `requirements.txt` (raíz del repositorio) con las dependencias fijadas
- `docs/etapa_1_mutual_information/mutual_info_ranking_24.csv` y `mutual_info_ranking_78.csv`
- `docs/etapa_2_decision_tree/feature_importance.csv` y `tree_rules.txt`
- `docs/etapa_3_random_forest_shap/rf_feature_importance.csv`, `shap_ranking.csv` y `shap_summary_plot.png`
- `docs/etapa_4_pca_umap/` para visualizaciones exploratorias
- `docs/etapa_5_sin_institucion_cv/random_forest_sin_institucion_cv.py`, `metrics_cv.csv` y `feature_importance_cv.csv`
- `docs/etapa_6_groupkfold_institucion/random_forest_groupkfold_institucion.py`, `metrics_groupkfold.csv` y `feature_importance_groupkfold.csv`
- `docs/etapa_7_permutation_importance/random_forest_permutation_importance.py` y `permutation_vs_mdi_importance.csv`
- `docs/etapa_8_modelo_final_honesto/random_forest_modelo_final.py`, `metrics_final.csv` y `feature_importance_final.csv`
- `docs/etapa_9_pca_umap_sin_institucion/pca_umap_sin_institucion.py`, `pca_explained_variance.csv` y `kmeans_silhouette_scores.csv`
- Scripts fuente `*_analysis.py` y sus README en cada carpeta

Los análisis se ejecutan con sus scripts documentados desde la raíz y leen `ESTU_MEDICINA_3_MODULOS.xlsx`. Este informe no modifica datos ni lógica de modelos; presenta los resultados ya calculados.

> **Conclusión:** dentro de las variables observadas, las características institucionales son las más asociadas con `PUNT_GLOBAL`, pero su poder predictivo aparente (R^2=0.37) estaba parcialmente inflado por compartir instituciones entre entrenamiento y prueba: bajo `GroupKFold` por institución el R^2 cae a 0.12±0.15. La permutation importance agrupada (sección 6.4) precisa además que esa señal institucional no es homogénea: el tipo de institución (`INST_ORIGEN`, `INST_CARACTER_ACADEMICO`) es señal real y generalizable, mientras que el nombre puntual de la institución es en gran parte memorización sin poder predictivo transferible a instituciones nuevas. El modelo final recomendado (sección 6.5, etapa 8) combina esa señal institucional real con las variables demográficas y socioeconómicas, excluyendo la memorización, y alcanza R^2=0.229±0.087 bajo la misma validación honesta por institución: es el resultado que el proyecto recomienda usar como desempeño de referencia y como feature set para cualquier uso real. El clustering no supervisado (sección 6.6, etapa 9) confirma lo mismo de forma independiente: los ~55 clusters de PCA/UMAP de la etapa 4 eran identidad institucional, y desaparecen al usar el feature set honesto. La magnitud y estabilidad causal de esa asociación requiere análisis temporal y diseños que controlen los mecanismos de selección.